

1- a) Pai 1: 000111      filho 1: 000110      b) Pai 1: 11011110      filho 1: 10001010 c) Pai 1: 1010  
filho1: 1001

Pai 2: 101010      filho 2: 101011      Pai 2: 00001010      filho 2: 01011110      Pai 2: 0101  
filho2: 0110

2 - população inicial

001100

010101

111000

000111

101011

101000

Avaliação da Aptidão (Fitness): Calcule o valor da aptidão (fitness) para cada indivíduo da população usando a função objetivo.

$Aptidão(001100) = (001100)^2 = 100$

$Aptidão(010101) = (010101)^2 = 2756$

$Aptidão(111000) = (111000)^2 = 12321$

$Aptidão(000111) = (000111)^2 = 49$

$Aptidão(101011) = (101011)^2 = 10372$

$Aptidão(101000) = (101000)^2 = 10201$

numeros com maior aptidão 111000 101011

cross over entre pais com maior aptidão com  $k = 3$  em

filho 1: 111011

filho 2: 101000

mutação aleatória em um gene:

filho 1 mutado: 111010

filho 2 mutado: 111000

5 O módulo de população em algoritmos evolucionários não reflete fielmente a natureza porque opera com um tamanho fixo

de população, controla a seleção com critérios de aptidão definidos pelo projetista, aplica operadores de crossover e

mutação de maneira controlada e simplificada, utiliza representações discretas e simplificadas de genes,

executa em ambientes artificiais de computador e tem como objetivo principal a otimização de metas específicas,

em contraste com a evolução na natureza, que é um processo complexo, estocástico e influenciado por interações

ecológicas, competição, predação e adaptação a mudanças ambientais em ambientes naturais dinâmicos e diversificados.

6 a)  $30 + 22 + 45 + 53 + 21 + 109 = 280$

intervalo de probabilidade 30 = 0 até 0.107

22 = 0.108 até 0.185

' 45 = 0.186 até 0.345

53 = 0.346 até 0.535

21 = 0.535 até 0.610

109 = 0.611 até 0.999

b)  $1 = 30$

$61 = 21$

$$82 = 109$$

$$285 = 45$$

$$21 = 45$$

$$279 = 45$$

$$6 = 30$$

$$0 = 30$$

7) 5 bits

8) 22 bits pois

$$\text{bits fracionários} = \log_2(1 / \text{Precisão})$$

precisão =  $10^{-5}$ :

$$\text{bits fracionários} = \log_2(1 / 10^{-5}) = \log_2(10^5) = 5 * \log_2(10) \approx 16.61 \text{ arredondando } 17 \text{ bits mais } 5 \text{ bits}$$

para a parte inteira e um para o sinal = 23 bits

11) com a taxa de mutação muito alta a população pode ficar muito aleatória e não corresponder a evolução esperada pela

população base escolhida

12) por que o operador de crossover leva em consideração o gene dos pais para gerar os filhos já a mutação é uma probabilidade

muito pequena e não leva a consideração os pais, então a genética não seria passada a frente, só seria alterada aleatoriamente

14) a mutação não é utilizada sozinha pois ela só altera aleatoriamente um gene quando é ativada e não leva em consideração

a genética dos pais como o crossover faz.

17) A convergência genética em um algoritmo evolucionário ocorre quando a população de indivíduos

evolui para um estado

onde a diversidade genética diminui e a maioria dos indivíduos se torna muito semelhante em termos de seus genótipos

(estruturas genéticas). Isso geralmente significa que o algoritmo convergiu para uma solução ótima ou subótima,

e a busca por novas soluções ou melhorias estagnou. Alguns métodos para evita-lá são: diversidade inicial, certificar-se

que a população será geneticamente diversa, operadores de mutação: ela pode mudar a genética da população aleatoriamente

de tempos em tempos adicionando variedade, tamanho da população: quanto maior a população menor a chance da variedade genética

ser pequena.

18) Um superindivíduo em um algoritmo evolucionário, devido à sua excepcional aptidão, pode levar à convergência genética

ao exercer uma forte pressão seletiva, limitar a exploração do espaço de busca, resultar na perda de diversidade genética

e causar estagnação da evolução, levando a uma população geneticamente homogênea e presa em ótimos locais subótimos.